

蔡雨洋

AI Infrastructure / LLM 推理系统 / 高性能计算

13061681696 | ycai07737@gmail.com | 2002.08 生 (23 岁) | 东南大学 · 2027 届



教育背景

东南大学 | 控制工程（电子信息）硕士

2024.09–2027.06（预计）

硕士生导师：孙长银教授（现任安徽大学校长、国家杰青、国家自然科学基金二等奖获得者）

东南大学 | 自动化（机器人工程）本科

2020.09–2024.06

荣誉：EDA 精英挑战赛全国一等奖（2024） | 线性解法器算法与性能优化竞赛全国三等奖（2025） | 嵌入式应用竞赛全国二等奖（2023） |

优秀毕业设计：融合 RL 动态约束决策、Transformer 时序预测与 Action Mapping 同胚变换，将状态依赖动作域映射至固定策略空间

实习经历

华为 | HPC / AI Infra 实习生

2026.06–至今

鲲鹏 920F · DeepSeek 推理通信 / INT8 IGEMM / 并行运行时优化

- 参与 DeepSeek V3/R1 MoE 通信优化：以 Verbs 批量 RDMA、RC Notify、QP 隔离和静态路由处理离散 Token Dispatch/Combine；EP=256、BS=64：Dispatch 48 μ s / 142 GB/s, Combine 84 μ s / 163 GB/s（峰值 200 GB/s）。
- 基于 Roofline 为鲲鹏 920F SME INT8 IGEMM 选择 L2 驻留微内核（左矩阵约束 micro_m $\leq$ 128、micro_k $\leq$ 2560）与 8 MOPA:1 Prefetch 流水；Decode IGEMM 内核有效带宽 320–360 GB/s，为 400 GB/s Stream 基准的 80%–90%。
- 融合 BF16 $\rightarrow$ INT8 Quant+Pack 与 FP32 Dequant+Save，按数据通路访存分别降至 0.6 $\times$ 、0.2 $\times$ ；以动态 tile、K-slice 与 N-slice 双专家调度适配动态 shape / Token 不均衡。
- 并行适配 SPECfem3D 网格染色与三维 Stencil，定位 Kokkos OpenMP 与 KU-PL pthread 共存导致的线程竞争和 CPU affinity 失效；使用 taskset、numactl、perf 分析 NUMA、缓存与内存布局。

开源项目

华为高性能推理优化赛道 | MiniCPM-o 4.5

2026.07–至今（在研）

昇腾 NPU 推理适配 / Benchmark / 性能与精度质量门

- 正在搭建模型适配、性能基线与复现链路，以 TTFT、chunk/E2E latency、吞吐/并发 session、资源利用率、稳定性和精度为联合评价指标；目标产出代码/配置、benchmark 脚本、性能报告与复现说明。

科研项目

随机化稀疏求解与性能工程

2025.07–2026.04

合作：陈晓明（中科院计算所、国家优青）、周振亚（华大九天研发副总、国家重大专项） · Solver 性能优化国三 · ICCAD 2026

- 拆解 MUMPS BLR 的 front 筛选 $\rightarrow$ 128–768 tile $\rightarrow$ RRQR $\rightarrow$ 低秩 TRSM/GEMM/重压缩；ASIC_680k 有效 factor-FLOP -93.6%、因子存储 -72%~73%，但 factor 4.841 $\rightarrow$ 4.896 s，定位 rank-4/8 skinny-GEMM 与重压缩/调度/搬运瓶颈。
- 24 核以 8 MPI $\times$ 3 OMP 将 wall 16.73 $\rightarrow$ 10.98 s (1.52 $\times$, W1 $\sim$ 10 $^{-14}$)；发现 MPI 映射可使 BLR 覆盖 23.9% $\rightarrow$ 0，且 L2 可驻留的 128 2 /rank-4 kernel 在 24 线程无收益，证明 tile/rank、任务粒度与线程团队须联调。

大规模多通道数值建模引擎

2024.09–至今

领衔 S 参数方向团队 · 苏仰锋（复旦数院、上海自然科学一等奖）/叶佐昌（清华集电、DAC TPC）指导 · EDA 全国一等奖 · ISEDA 2025

- 将 MATLAB 串行 QR/VF 重构为 C++17 多阶段并行引擎；经 BDCSVD/宽矩阵 Gram 将 26,335 通道压至 rank 67，再在低维多 RHS 上迁移公共极点并回投影，229 端口 graphs 达 0.358% 误差、1.95 s 总时延。
- 按依赖图并行 channel/frequency/record，以 static/dynamic 匹配任务规则性；配合直接实数 QR、one-pass parser、谱范数复用与 16 MiB 缓冲输出，ART12 1 $\rightarrow$ 8 线程 20.91 $\rightarrow$ 7.85 s (2.66 $\times$)，452 MiB 读 0.49 s、写 1.4 $\rightarrow$ 0.33 s (-76%)。

社区协作

SGLang-Omni / vLLM Meetup | 推理系统社区协作

2026.04–至今

- 参与 SGLang-Omni、vLLM Meetup 与 WAIC LLM/Agent Night 的推理系统交流；围绕多阶段生成/全双工 runtime，梳理可写 SessionRequest、实时 tick 混合 prefill/decode 与滑动 KV 窗口，以 session-aware 调度处理连续输入、打断与 tail latency。

北京大学未名超算队 $\times$ LCPU | AI Infra Seminars

2026.07–至今

七周专题：Kernel / 集合通信 / LLM Serving / 分布式 RL