

蔡雨洋

AI Infrastructure / LLM 推理系统 / 高性能计算

13061681696 | ycai07737@gmail.com | 2002.08 生 (23 岁) | 东南大学 · 2027 届



教育背景

东南大学 | 控制工程 (电子信息) 硕士

2024.09–2027.06 (预计)

硕士生导师: 孙长银教授 (现任安徽大学校长、国家杰青、国家自然科学基金二等奖获得者)

东南大学 | 自动化 (机器人工程) 本科

2020.09–2024.06

荣誉: EDA 精英挑战赛全国一等奖 (2024) | 线性解法器算法与性能优化竞赛全国三等奖 (2025) | 嵌入式应用竞赛全国二等奖 (2023) |

优秀毕业设计: 融合 RL 动态约束决策、Transformer 时序预测与 Action Mapping 同胚变换, 将状态依赖动作域映射至固定策略空间

实习经历

华为 | HPC / AI Infra 实习生

2026.06–至今

鲲鹏 920F · DeepSeek 推理通信 / INT8 IGEMM / 并行运行时优化

- 参与 DeepSeek V3/R1 MoE 通信优化: 以 Verbs 批量 RDMA、RC Notify、QP 隔离和静态路由处理离散 Token Dispatch/Combine; EP=256、BS=64: Dispatch 48 μ s / 142 GB/s, Combine 84 μ s / 163 GB/s (峰值 200 GB/s)。
- 基于 Roofline 为鲲鹏 920F SME INT8 IGEMM 选择 L2 驻留微内核 (左矩阵约束 micro_m $\leq$ 128、micro_k $\leq$ 2560) 与 8 MOPA:1 Prefetch 流水; Decode IGEMM 内核有效带宽 320–360 GB/s, 为 400 GB/s Stream 基准的 80%–90%。
- 融合 BF16 $\rightarrow$ INT8 Quant+Pack 与 FP32 Dequant+Save, 按数据通路访存分别降至 0.6 $\times$ 、0.2 $\times$; 以动态 tile、K-slice 与 N-slice 双专家调度适配动态 shape / Token 不均衡。
- 并行适配 SPECfem3D 网格染色与三维 Stencil, 定位 Kokkos OpenMP 与 KU-PL pthread 共存导致的线程竞争和 CPU affinity 失效; 使用 taskset、numactl、perf 分析 NUMA、缓存与内存布局。

开源项目

华为高性能推理优化赛道 | MiniCPM-o 4.5

2026.07–至今 (在研)

昇腾 NPU 推理适配 / Benchmark / 性能与精度质量门

- 正在搭建模型适配、性能基线与复现链路, 以 TTFT、chunk/E2E latency、吞吐/并发 session、资源利用率、稳定性和精度为联合评价指标; 目标产出代码/配置、benchmark 脚本、性能报告与复现说明。

科研项目

随机化稀疏求解与性能工程

2025.07–2026.04

合作: 陈晓明 (中科院计算所、国家优青)、周振亚 (华大九天研发副总、国家重大专项) · Solver 性能优化国三 · ICCAD 2026

- 面向 Sparse Linear Algebra workload, 建立 MUMPS 消除树/多重前沿 factor 的 MPI $\times$ OpenMP $\times$ BLAS 性能模型; 24 核数值内核达 419 GFLOP/s、为同机 DGEMM 持续峰值的 40.9% (3 次 CV 0.47%, W1 $\sim$ 10 $^{-15}$), 以 front 粒度与 BLAS-3 聚合定位利用率瓶颈。

大规模多通道数值建模引擎

2024.09–至今

领衔 S 参数方向团队 · 苏仰锋 (复旦数院、上海自然科学一等奖) / 叶佐昌 (清华集电、DAC TPC) 指导 · EDA 全国一等奖 · ISEDA 2025

- 将多通道拟合重构为共享子空间压缩 $\rightarrow$ 公共极点迁移 $\rightarrow$ 多 RHS 求解 $\rightarrow$ 回投影的多阶段计算图; 以截断 SVD 按尾能量自适应选秩, 将后续有效维度压缩约 393 $\times$, 对应配置误差 0.358%。
- 按依赖图并行 channel/frequency/record, 以 static/dynamic 匹配任务规则性; 用 power iteration、复数 GEMV 与谱范数缓存重构质量门禁, 校验阶段加速 13.8 $\times$ 、总时延降低 65%–70%, 误差差值仅 0.001758 个百分点, 并以 checkpoint/rollback 约束选阶与数值质量。

社区协作

SGLang-Omni / vLLM Meetup | 推理系统社区协作

2026.04–至今

- 参与 SGLang-Omni、vLLM Meetup 与 WAIC LLM/Agent Night 的推理系统交流; 围绕多阶段生成/全双工 runtime, 梳理可写 SessionRequest、实时 tick 混合 prefill/decode 与滑动 KV 窗口, 以 session-aware 调度处理连续输入、打断与 tail latency。

北京大学未名超算队 $\times$ LCPU | AI Infra Seminars

2026.07–至今

七周专题: Kernel / 集合通信 / LLM Serving / 分布式 RL