

蔡雨洋

AI Infrastructure / LLM 推理系统 / 高性能计算

13061681696 | ycai07737@gmail.com | 2002.08 生 (23 岁) | 东南大学 · 2027 届



教育背景

东南大学 | 控制工程（电子信息）硕士

2024.09–2027.06（预计）

硕士生导师：孙长银教授（现任安徽大学校长、国家杰青、国家自然科学基金二等奖获得者）

东南大学 | 自动化（机器人工程）本科

2020.09–2024.06

荣誉：CPIPC 创“芯”大赛全国一等奖（2024） | 线性解法器算法与性能优化竞赛全国三等奖（2025） | 嵌入式应用竞赛全国二等奖（2023）

| 优秀毕业设计：融合 RL 动态约束决策、Transformer 时序预测与 Action Mapping 同胚变换，将状态依赖动作域映射至固定策略空间

实习经历

华为 | HPC / AI Infra 实习生

2026.06–至今

鲲鹏 920F · DeepSeek 推理通信 / INT8 IGEMM / 并行运行时优化

- 参与 DeepSeek V3/R1 MoE 通信优化：以 Verbs 批量 RDMA、RC Notify、QP 隔离和静态路由处理离散 Token Dispatch/Combine；EP=256、BS=64：Dispatch 48 μ s / 142 GB/s, Combine 84 μ s / 163 GB/s（峰值 200 GB/s）。
- 基于 Roofline 为鲲鹏 920F SME INT8 IGEMM 选择 L2 驻留微内核（左矩阵约束 micro_m $\leq$ 128、micro_k $\leq$ 2560）与 8 MOPA:1 Prefetch 流水；Decode IGEMM 内核有效带宽 320–360 GB/s，为 400 GB/s Stream 基准的 80%–90%。
- 融合 BF16 $\rightarrow$ INT8 Quant+Pack 与 FP32 Dequant+Save，按数据通路访存分别降至 0.6 $\times$ 、0.2 $\times$ ；以动态 tile、K-slice 与 N-slice 双专家调度适配动态 shape / Token 不均衡。

开源项目

MiniCPM-o 4.5 | vLLM-Omni 昇腾推理优化（华为赛道）

2026.07–至今（在研）

Ascend 910C · Stage pipeline / NPU kernel & layout / A/B/A gates

- 基于赛题分支与公开 910C profile，建立 TTFT/RTT $\rightarrow$ Stage 0/1/2 队列 $\rightarrow$ 算子分解：Stage 2 中 97.4% kernel $\leq$ 50 μ s、布局转换占聚合算子时间 36.6%，据此设计双 Die 阶段映射、inner NPU Graph 与 layout/cache 重构的 A/B/A 实验卡；个人 910C 收益待实测。

TencentDB Agent Memory | Recall 状态与 Prompt Cache 稳定性

2026.07–2026.08

腾讯犀牛鸟开源人才培养活动获奖 · 获奖比例 3% · OpenClaw 2026.5.28 / DeepSeek V4 Pro

- 修复动态 Recall 注入与历史写回不一致：以 append-only Ledger 原样持久化，DeepSeek V4 Pro cache hit 71.36% $\rightarrow$ 99.53%。
- 抑制重复 Recall 导致的上下文膨胀：按 ID/revision/content hash 去重并设 32k cap，50 轮回归保持稳定。

科研项目

随机化稀疏求解与性能工程

2025.07–2026.04

合作：陈晓明（中科院计算所）、周振亚（华大九天研发副总） · Solver 性能优化国三 · ICCAD 2026 一作

- 面向 Sparse Linear Algebra workload，建立 MUMPS 消除树/多重前沿 factor 的 MPI $\times$ OpenMP $\times$ BLAS 性能模型；24 核数值内核达 419 GFLOP/s、为同机 DGEMM 持续峰值的 40.9%（3 次 CV 0.47%，W1 $\sim$ 10⁻¹⁵），以 front 粒度与 BLAS-3 聚合定位利用率瓶颈。

大规模多通道数值建模引擎

2024.09–2024.12

领衔 S 参数方向团队 · 苏仰锋（复旦、上海自科一等奖）/叶佐昌（清华、DAC TPC）指导 · CPIPC 创“芯”大赛国一 · ISEDA 2025

- 将多通道拟合重构为共享子空间压缩 $\rightarrow$ 公共极点迁移 $\rightarrow$ 多 RHS 求解 $\rightarrow$ 回投影的多阶段计算图；以截断 SVD 按尾能量自适应选秩，将后续有效维度压缩约 393 $\times$ ，对应配置误差 0.358%。
- 按依赖图并行 channel/frequency/record，以 static/dynamic 匹配任务规则性；用 power iteration、复数 GEMV 与谱范数缓存重构质量门禁，校验阶段加速 13.8 $\times$ 、总时延降低 65%–70%，误差差值仅 0.001758 个百分点，并以 checkpoint/rollback 约束选阶与数值质量。

社区协作

SGLang-Omni / vLLM Meetup | 推理系统社区协作

2026.04–至今

- 参与 SGLang-Omni ASR PR/CI 讨论，复核 CUDA Graph batch policy、continuous prefill/KV Cache 与全双工调度。

北京大学未名超算队 $\times$ LCPU | AI Infra Seminars

2026.07–至今

TileLang：SAXPY / block 内归约 / softmax，3 题均 100 分 Accepted · B300 SXM6 / Slurm 实践